Conceptos básicos de Machine Learning



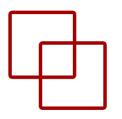
ETS de Ingeniería Informática

Dr. Manuel Castillo-Cara

www.manuelcastillo.eu

Departamento de Inteligencia Artificial Escuela Técnica Superior de Ingeniería Informática Universidad Nacional de Educación a Distancia (UNED)

Preliminar



• Improving Deep Learning by Exploiting Synthetic Images © 2024 by Manuel Castillo-Cara is licensed under Attribution-NonCommercial 4.0 International



Attribution-NonCommercial 4.0 International (CC BY-NC 4.0)



ETS de Ingeniería Informática

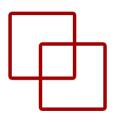
Índice

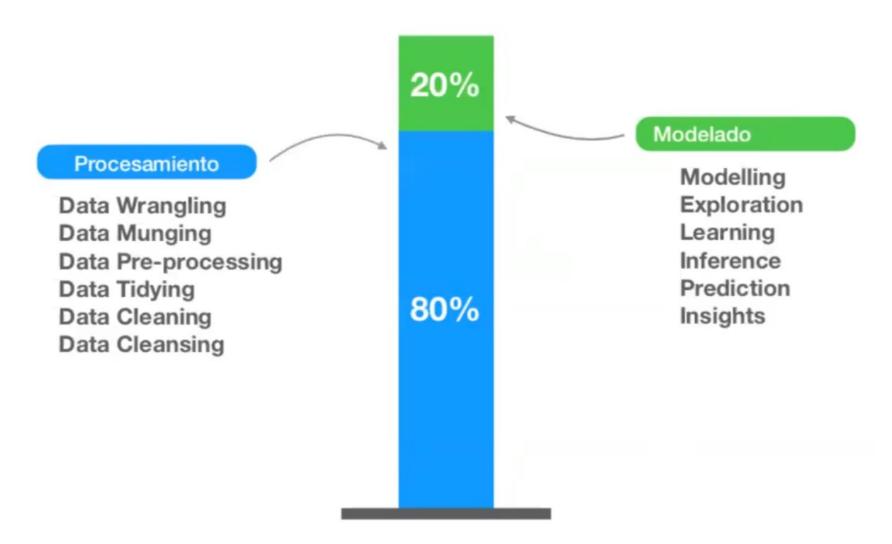
- Fuentes de datos.
- Tipos de problema
- Tipos de problema en datasets.

Fuentes de datos

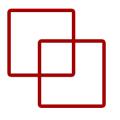


Procesamiento de datos – Tarea que más tiempo consume





Formato de los datos



• Es un problema real, los datos originales no vendrán en un formato propicio para su análisis directo (estructurado)

Sepal LengthCM	Sepal WidthCm	Petal LengthCm	Petal WidthCm	Species
5.1	3.5	1.4	0.2	setosa
4.9	3	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
4.6	3.1	1.5	0.2	setosa
5	3.6	1.4	0.2	setosa
5.4	3.9	1.7	0.4	setosa
4.6	3.4	1.4	0.3	setosa
5	3.4	1.5	0.2	setosa
4.4	2.9	1.4	0.2	setosa
4.9	3.1	1.5	0.1	setosa
5.4	3.7	1.5	0.2	setosa
4.8	3.4	1.6	0.2	setosa
4.8	3	1.4	0.1	setosa
4.3	3	1.1	0.1	setosa

Tidy data

"Tidy data is a standard way of mapping the meaning of a dataset to its structure. A dataset is messy or tidy depending on how rows, columns and tables are matched up with observations, variables and types"

Hadley Wickham 2014 (Tidy Data - Journal of Statistical Software)

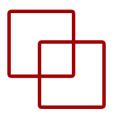


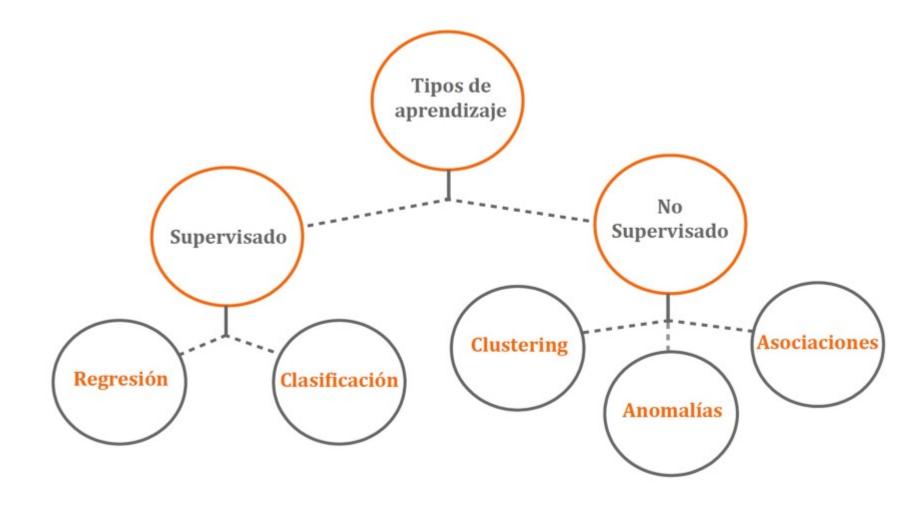
- Un dataset "Tidy" mantiene las siguientes **propiedades**:
 - Cada variable representa una columna
 - Cada observación representa una fila
 - Cada unidad observacional representa una tabla
- Permite definir objetivos, estrategias y herramientas **estandarizadas** para la limpieza y transformación de datos.
- Permite definir un vocabulario y operadores de transformación desde un punto de vista **agnóstico a cualquier lenguaje**.
- Artículo: Wickham, H. (2014). Tidy data. Journal of Statistical Software

Tipos de aprendizaje

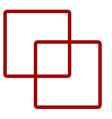


Tipos de aprendizaje



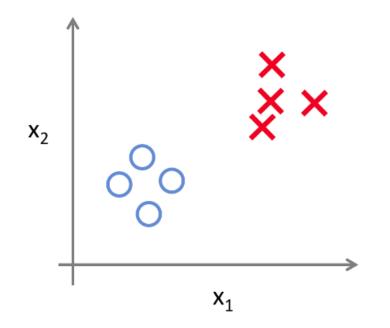


Aprendizaje Supervisado

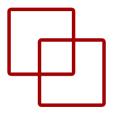


- Los algoritmos trabajan con datos "etiquetados" (*labeled data*).
- **Objetivo**: encontrar una función que, dadas las variables de entrada (*input data*), les asigne la etiqueta de salida adecuada.
- Entrenamiento con un "histórico" de datos para "aprender" a asignar la etiqueta de salida.
- Función final: predecir el valor de salida.

Supervised Learning



Aprendizaje supervisado

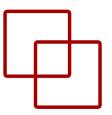


Permite a las organizaciones comprender y prevenir los resultados no deseados o impulsar los resultados deseados para lo que sea que estén tratando de predecir

Los modelos deben ser reconstruidos periódicamente con el fin de mantener sus predicciones sin que se conviertan en obsoletas

Proporciona una ruta directa para convertir datos en información real y procesable Este aprendizaje es uno de los motores más potentes que permite que los sistemas de inteligencia artificial tomen decisiones empresariales de forma más rápida y precisa que los humanos

Clasificación Vs. Regresión

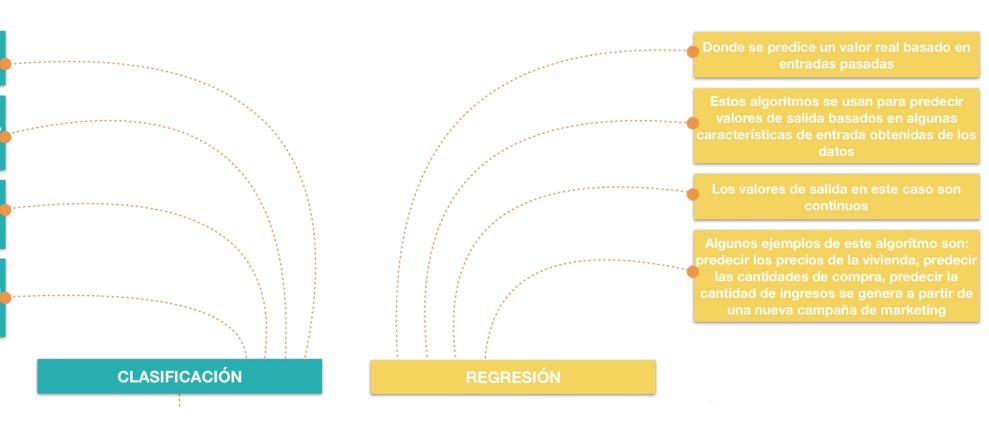


El algoritmo intenta etiquetar cada ejemplo eligiendo entre dos o más clases diferentes

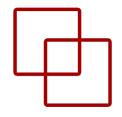
Usan las características aprendidas de los datos de capacitación sobre datos nuevos, no vistos previamente, para predecir sus etiquetas de clase

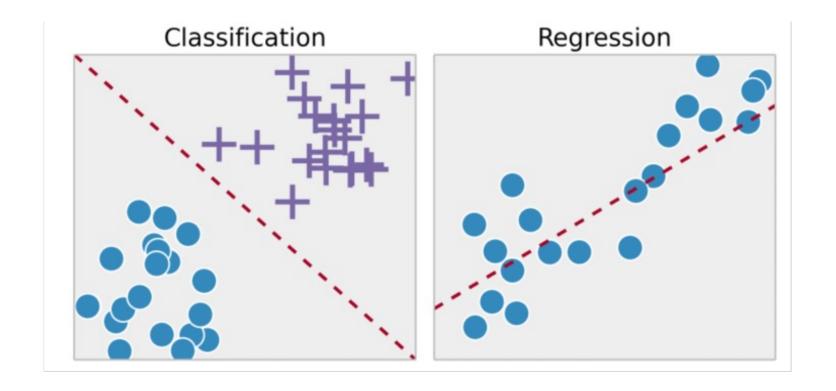
Elegir entre dos clases se denomina clasificación binaria. Elegir entre más de dos clases se denomina clasificación multiclase

Algunos ejemplos de este algoritmo son: predecir si un cliente va a cancelar o no su tarjeta de crédito, predecir si un alumno pasará o no una clase



Clasificación Vs. Regresión



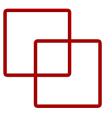




(a) Muestra de un atributo nominal.

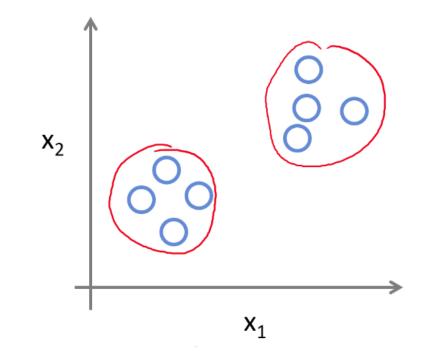
(b) Muestra de un atributo numérico.

Aprendizaje No Supervisado

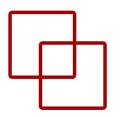


- No se dispone de datos "etiquetados" para el entrenamiento.
- Sólo se conocen los datos de entrada, pero no tienen atributo clase (dato de salida).
- Sólo pueden describirse la estructura de los datos.
- Objetivo: Encontrar algún tipo de organización que simplifique el análisis.
- Por ello, tienen un carácter exploratorio.
 - (Ejemplo de un txt de Weka el atributo clase).

Unsupervised Learning



SLAs Vs. ULAs



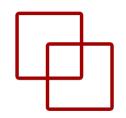
r	A	В	С	D	E	F	G	Н	I	
1	preg	plas	pres	skin	insu	mass	pedi	age	class	
2	1	85	66	29	0	26.6	351	31	tested_negative	
3	5	116	74	0	0	25.6	201	30	tested_negative	
4	10	115	0	0	0	35.3	134	29	tested_negative	
5	4	110	92	0	0	37.6	191	30	tested_negative	
6	10	139	80	0	0	27.1	1441	57	tested_negative	
7	8	99	84	0	0	35.4	388	50	tested_negative	
8	5	117	92	0	0	34.1	337	38	tested_negative	
9	5	109	75	26	0	36	546	60	tested_negative	

¿Tipo problema?

r	A	В	С	D	Е	F	G	Н
1	preg	plas	pres	skin	insu	mass	pedi	age
2	1	85	66	29	0	26.6	351	31
3	5	116	74	0	0	25.6	201	30
4	10	115	0	0	0	35.3	134	29
5	4	110	92	0	0	37.6	191	30
6	10	139	80	0	0	27.1	1441	57
7	8	99	84	0	0	35.4	388	50
8	5	117	92	0	0	34.1	337	38
9	5	109	75	26	0	36	546	60

¿Tipo problema?

SLAs Vs. ULAs



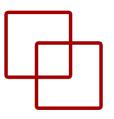
r	A	В	C	D	E	F	G	Н	I	_
1	preg	plas	pres	skin	insu	mass	pedi	age	class	
2	1	85	66	29	0	26.6	351	31	tested_negative	
3	5	116	74	0	0	25.6	201	30	tested_negative	
4	10	115	0	0	0	35.3	134	29	tested_negative	
5	4	110	92	0	0	37.6	191	30	tested_negative	
6	10	139	80	0	0	27.1	1441	57	tested_negative	
7	8	99	84	0	0	35.4	388	50	tested_negative	
8	5	117	92	0	0	34.1	337	38	tested_negative	
9	5	109	75	26	0	36	546	60	tested_negative	

Supervisado

	A	В	С	D	Е	F	G	Н
1	preg	plas	pres	skin	insu	mass	pedi	age
2	1	85	66	29	0	26.6	351	31
3	5	116	74	0	0	25.6	201	30
4	10	115	0	0	0	35.3	134	29
5	4	110	92	0	0	37.6	191	30
6	10	139	80	0	0	27.1	1441	57
7	8	99	84	0	0	35.4	388	50
8	5	117	92	0	0	34.1	337	38
9	5	109	75	26	0	36	546	60

No Supervisado

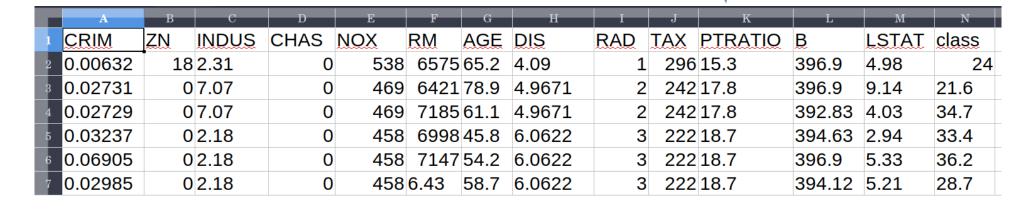
Regresión Vs. Clasificación



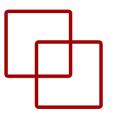
	A	В	C	D	Е	F	G	Н	I
1	preg	plas	pres	skin	insu	mass	pedi	age	class
2	1	85	66	29	0	26.6	351	31	tested_negative
3	5	116	74	0	0	25.6	201	30	tested_negative
4	10	115	0	0	0	35.3	134	29	tested_negative
5	4	110	92	0	0	37.6	191	30	tested_negative
6	10	139	80	0	0	27.1	1441	57	tested_negative
7	8	99	84	0	0	35.4	388	50	tested_negative
8	5	117	92	0	0	34.1	337	38	tested_negative
9	5	109	75	26	0	36	546	60	tested_negative

¿Tipo problema?

¿Tipo problema?



Regresión Vs. Clasificación



	A	В	C	D	Е	F	G	Н	I
1	preg	plas	pres	skin	insu	mass	pedi	age	class
2	1	85	66	29	0	26.6	351	31	tested_negative
3	5	116	74	0	0	25.6	201	30	tested_negative
1	10	115	0	0	0	35.3	134	29	tested_negative
5	4	110	92	0	0	37.6	191	30	tested_negative
3	10	139	80	0	0	27.1	1441	57	tested_negative
,	8	99	84	0	0	35.4	388	50	tested_negative
B	5	117	92	0	0	34.1	337	38	tested_negative
)	5	109	75	26	0	36	546	60	tested_negative

Clasificación

Regresión

	A	В	С	D	E	F	G	Н	I	J	K	L	M	N
1	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	<u>B</u>	LSTAT	class
2	0.00632	18	2.31	0	538	6575	65.2	4.09	1	296	15.3	396.9	4.98	24
3	0.02731	0	7.07	0	469	6421	78.9	4.9671	2	242	17.8	396.9	9.14	21.6
4	0.02729	0	7.07	0	469	7185	61.1	4.9671	2	242	17.8	392.83	4.03	34.7
5	0.03237	0	2.18	0	458	6998	45.8	6.0622	3	222	18.7	394.63	2.94	33.4
6	0.06905	0	2.18	0	458	7147	54.2	6.0622	3	222	18.7	396.9	5.33	36.2
7	0.02985	0	2.18	0	458	6.43	58.7	6.0622	3	222	18.7	394.12	5.21	28.7

Tipos de problema en datasets



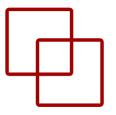
Iris

- Dimensiones: 150 instancias, 5 atributos.
- Entradas: Numéricas.

```
1 > data(iris)
2 > head(iris)
    Sepal.Length Sepal.Width Petal.Length Petal.Width Species
              5.1
                          3.5
                                       1.4
                                                    0.2 setosa
             4.9
                          3.0
                                       1.4
                                                    0.2 setosa
                          3.2
                                       1.3
             4.7
                                                    0.2 setosa
                          3.1
                                       1.5
             4.6
                                                    0.2 setosa
8 5
                          3.6
                                       1.4
              5.0
                                                    0.2 setosa
9 6
              5.4
                          3.9
                                        1.7
                                                    0.4 setosa
```

CÓDIGO 2.25: Resumen del conjunto de datos Iris

Económica de Longley

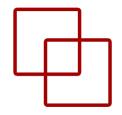


- Descripción: Predecir el número de personas empleadas a partir de variables económicas.
- Dimensiones: 16 instancias, 7 atributos.
- Entradas: Numéricas.

1 2	> data(1	ongley)											
2 2	> head(longley)												
3	GN	NP. deflator	GNP	Unemployed	$Armed.\ Forces$	Population	Year						
4	1947	83.0	234.289	235.6	159.0	107.608	1947						
5	1948	88.5	259.426	232.5	145.6	108.632	1948						
6	1949	88.2	258.054	368.2	161.6	109.773	1949						
7	1950	89.5	284.599	335.1	165.0	110.929	1950						
8	1951	96.2	328.975	209.9	309.9	112.075	1951						
9	1952	98.1	346.999	193.2	359.4	113.270	1952						

CÓDIGO 2.26: Resumen del conjunto de datos Longley

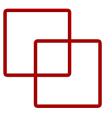
Boston Housing



- Descripción: Predecir el precio medio de una casa en los suburbios de Boston.
- Dimensiones: 506 instancias, 14 atributos.
- Entradas: Numéricas.

```
> data(BostonHousing)
> head(BostonHousing)
    crim zn indus chas
                                           dis rad tax ptratio
                                rm age
                         nox
1 0.00632 18 2.31
                     0 0.538 6.575 65.2 4.0900
                                                 1 296
                                                         15.3 396.90
                     0 0.469 6.421 78.9 4.9671
2 0.02731 0 7.07
                                                2 242
                                                         17.8 396.90
3 0.02729 0 7.07
                     0 0.469 7.185 61.1 4.9671
                                                2 242
                                                         17.8 392.83
4 0.03237 0 2.18
                     0 0.458 6.998 45.8 6.0622
                                                3 222
                                                         18.7 394.63
5 0.06905 0 2.18
                     0 0.458 7.147 54.2 6.0622
                                                 3 222
                                                         18.7 396.90
6 0.02985 0 2.18
                     0 0.458 6.430 58.7 6.0622
                                                 3 222
                                                         18.7 394.12
 lstat medv
1 4.98 24.0
2 9.14 21.6
 4.03 34.7
4 2.94 33.4
  5.33 36.2
  5.21 28.7
```

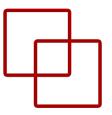
BreastCancer Wisconsin



- Descripción: Predecir si una muestra de tejido es maligna o benigna dadas propiedades sobre la muestra de tejido.
- Dimensiones: 699 instancias, 11 atributos.
- Entradas: Entero (Nominal).

>	data(Breast	Cancer)					
>	head(Breast	Cancer)					
	Id Cl.	thickness Ce	ll.size	Cell.shape	Marg.a	adhesion	Epith.c.size
1	1000025	5	1	1		1	2
2	1002945	5	4	4		5	7
3	1015425	3	1	1		1	2
4	1016277	6	8	8		1	3
5	1017023	4	1	1		3	2
6	1017122	8	10	10		8	7
	Bare.nuclei	Bl.cromatin	Normal	.nucleoli Mi	itoses	Clas	s
1	1	3		1	1	benig	n
2	10	3		2	1	benig	n
3	2	3		1	1	benig	n
4	4	3		7	1	benig	n
5	1	3		1	1	benig	n
6	10	9)	7	1	malionan	t

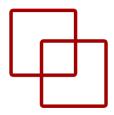
Identificación de vidrio



- Descripción: Predecir el tipo de vidrio a partir de propiedades químicas.
- Dimensiones: 244 instancias, 10 atributos.
- Entradas: Numérico.

```
> data(Glass)
> head(Glass)
                            Si
            Na
                      Αl
                                  K Ca Ba
                                              Fe Type
1 1.52101 13.64 4.49 1.10 71.78 0.06 8.75
2 1.51761 13.89 3.60 1.36 72.73 0.48 7.83
                                          0 0.00
3 1.51618 13.53 3.55 1.54 72.99 0.39 7.78
                                          0 0.00
4 1.51766 13.21 3.69 1.29 72.61 0.57 8.22
                                          0 0.00
5 1.51742 13.27 3.62 1.24 73.08 0.55 8.07
                                          0 0.00
6 1.51596 12.79 3.61 1.62 72.97 0.64 8.07
                                          0 0.26
```

Ionosphere

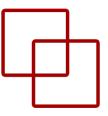


- Descripción: Predecir estructuras de alta energía en la atmósfera a partir de datos de antena.
- Dimensiones: 351 instancias, 35 atributos.
- Entradas: Numérico.

- > data(Ionosphere)
- > head(Ionosphere)

```
V34 Class
V1 V2
           V3
                    ٧4
                              V5
                                       V6
                                                V7
                                                         V8
                                                                  V9
                                                                       0.45300
                                                                                 good
                                           0.83398 -0.37708 1.00000
    0 0.99539 -0.05889
                        0.85243
                                  0.02306
                                                                                  bad
                                                                       0.02447
    0 1.00000 -0.18829
                        0.93035 -0.36156 -0.10868 -0.93597 1.00000
                                                                       0.38238
                                                                                 good
    0 1.00000 -0.03365
                        1.00000
                                  0.00485
                                           1.00000 -0.12062 0.88965
                                                                                  bad
                                                                       1.00000
    0 1.00000 -0.45161
                        1.00000
                                  1.00000
                                           0.71216 -1.00000 0.00000
                                                                       0.65697
                                           0.92106 -0.23255 0.77152
                                                                                 dood
    0 1.00000 -0.02401
                        0.94140
                                  0.06531
                                                                       0.12011
                                                                                  bad
    0 0.02337 -0.00592 -0.09924 -0.11949 -0.00763 -0.11824 0.14706
```

Diabetes de Pima Indians

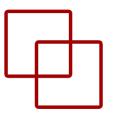


- Descripción: Predecir el inicio de la diabetes en mujeres indias pima a partir de datos de registros médicos.
- Dimensiones: 768 instancias, 9 atributos.
- Entradas: Numérico.

- > data(PimaIndiansDiabetes)
- > head(PimaIndiansDiabetes)

	pregnant	glucose	pressure	triceps	insulin	mass	pedigree	age	${\tt diabetes}$
1	6	148	72	35	0	33.6	0.627	50	pos
2	1	85	66	29	0	26.6	0.351	31	neg
3	8	183	64	0	0	23.3	0.672	32	pos
4	1	89	66	23	94	28.1	0.167	21	neg
5	0	137	40	35	168	43.1	2.288	33	pos
6	5	116	74	0	0	25.6	0.201	30	neg

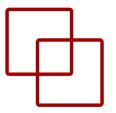
Sonar, Mines vs. Rocks



- Descripción: Predice los retornos de metal o roca a partir de los datos de retorno del sonar.
- Dimensiones: 208 instancias, 61 atributos.
- Entradas: Numérico.
- > data(Sonar)
- > head(Sonar)

```
V1
                    V3
                           V4
                                  V5
                                         ۷6
                                                        V8
                                                               V9
                                                                     V10 Class
1 0.0200 0.0371 0.0428 0.0207 0.0954 0.0986 0.1539 0.1601 0.3109 0.2111
                                                                             R
2 0.0453 0.0523 0.0843 0.0689 0.1183 0.2583 0.2156 0.3481 0.3337 0.2872
3 0.0262 0.0582 0.1099 0.1083 0.0974 0.2280 0.2431 0.3771 0.5598 0.6194
                                                                             R
4 0.0100 0.0171 0.0623 0.0205 0.0205 0.0368 0.1098 0.1276 0.0598 0.1264
                                                                             R
5 0.0762 0.0666 0.0481 0.0394 0.0590 0.0649 0.1209 0.2467 0.3564 0.4459
                                                                             R
6 0.0286 0.0453 0.0277 0.0174 0.0384 0.0990 0.1201 0.1833 0.2105 0.3039
```

Base de datos Soya



- Descripción: Predecir problemas con cultivos de soja a partir de datos de cultivos.
- Dimensiones: 683 instancias, 26 atributos.
- Entradas: Entero (Nominal).

```
> data(Soybean)
> head(Soybean)

Class date plant.stand precip temp hail crop.hist
1 diaporthe-stem-canker 6 0 2 1 0 1
2 diaporthe-stem-canker 4 0 2 1 0 2
3 diaporthe-stem-canker 3 0 2 1 0 1
4 diaporthe-stem-canker 3 0 2 1 0 1
5 diaporthe-stem-canker 6 0 2 1 0 2
6 diaporthe-stem-canker 5 0 2 1 0 3
```

GRACIAS!



ETS de Ingeniería Informática

Dr. Manuel Castillo-Cara

www.manuelcastillo.eu

Departamento de Inteligencia Artificial Escuela Técnica Superior de Ingeniería Informática Universidad Nacional de Educación a Distancia (UNED)